
Analítica Big Data y Modelamiento Predictivo sobre Incidentes Criminales en Chicago (2001–Presente)

Evaluación 4 Big Data

NOMBRE: Matías Madrid Rojas y Luis Orellana Yáñez

CARRERA: Ingeniería en Informática

ASIGNATURA: Big Data

PROFESOR: Alberto Gabriel Marambio Riveros

FECHA: 15/12/2025

Contenido

1	Introducción	3
2	Propósito del trabajo y contexto de negocio	4
3	Requerimientos del negocio y criterios de aceptación	4
4	Dataset, volumen y justificación del enfoque Big Data	5
5	Preparación de datos y construcción de la vista minable	5
5.1	Estandarización de columnas	5
5.2	Conversión robusta de fecha y creación de variables temporales	5
5.3	Selección de variables y filtrado crítico	6
5.4	Deduplicación	6
6	Almacenamiento eficiente: Parquet particionado por año	6
7	Análisis exploratorio y evidencia visual	7
8	Modelos aplicados, configuración, evaluación e interpretación	9
8.1	Modelo 1: Clasificación de arresto (Logistic Regression)}	9
8.2	Modelo 2: Regresión de volumen de delitos por distrito/mes (GBTRegressor)	11
8.3	Modelo 3: Clustering espacio-temporal (K-Means)	12
9	Evaluación integral, consistencia y reproducibilidad	13
10	Limitaciones y consideraciones de uso responsable	14
11	Conclusiones finales	15
12	Anexos	16

1 Introducción

En la actualidad, las instituciones públicas enfrentan un desafío creciente en la gestión y análisis de grandes volúmenes de datos generados por sus propias operaciones. En el ámbito de la seguridad ciudadana, los registros históricos de incidentes criminales son una fuente de información de alto valor estratégico, sin embargo, su tamaño, heterogeneidad y complejidad dificultan el uso de herramientas tradicionales de análisis. En este contexto, el enfoque de Big Data se vuelve indispensable para transformar datos masivos en conocimiento útil que apoye la toma de decisiones basada en evidencia.

La ciudad de Chicago tiene a disposición pública un repositorio histórico de incidentes criminales que abarca más de dos décadas de información, superando los ocho millones de registros. Este conjunto de datos tiene variables temporales, geográficas y administrativas que permiten analizar patrones de ocurrencia, evaluar tendencias y desarrollar modelos predictivos y descriptivos. No obstante, para explotar adecuadamente este tipo de información es necesario aplicar técnicas de procesamiento distribuido, limpieza robusta de datos y algoritmos de Machine Learning escalables.

Este trabajo tiene como propósito diseñar y ejecutar un flujo completo de analítica Big Data sobre el dataset Chicago Crime Incidents (2001–Presente), utilizando Apache Spark en un entorno distribuido. A partir de este flujo, se implementan distintos enfoques de Machine Learning (clasificación, regresión y clustering) orientados a responder requerimientos de un escenario institucional, tales como la priorización operativa, la planificación de recursos y la segmentación territorial y temporal de los incidentes.

El desarrollo se enfoca en la construcción de una vista minable, el almacenamiento eficiente de los datos en formato columnar, la aplicación de algoritmos adecuados al volumen y naturaleza de la información, y la evaluación de los resultados obtenidos mediante métricas estándar.

2 Propósito del trabajo y contexto de negocio

El problema abordado se sitúa en un escenario de gestión pública de seguridad ciudadana, donde una el gobierno local de Chicago requiere convertir grandes volúmenes de registros históricos de incidentes criminales en información accionable. En este contexto, la necesidad no es únicamente “analizar el pasado”, sino anticipar demanda, focalizar patrullajes, planificar recursos, y evaluar patrones territoriales y temporales de ocurrencia.

El dataset utilizado contiene incidentes desde 2001 hasta la actualidad, con variables temporales, administrativas y de localización. Ese alcance temporal extenso permite construir tendencias y modelos que capturan estacionalidad (mes), comportamiento intradía (hora) y diferencias territoriales (distrito), lo cual es consistente con requerimientos típicos de política pública.

3 Requerimientos del negocio y criterios de aceptación

Para que el trabajo sea útil en un entorno institucional, se definieron requerimientos orientados a decisiones concretas y verificables.

En primer lugar, la institución requiere priorización operativa. No todos los incidentes tienen el mismo comportamiento, en particular, existe interés en estimar la probabilidad de que un incidente termine en arresto. Esto permite apoyar decisiones como: dónde reforzar presencia policial, qué contextos presentan menor efectividad de intervención, y cómo ajustar protocolos. Por ello se exige un modelo de clasificación con métricas interpretables.

En segundo lugar, se requiere planificación de recursos. La unidad de planificación policial necesita anticipar carga por zona y período (por ejemplo, delitos mensuales por distrito) para turnos, vehículos y dotación. Esto requiere un modelo de regresión que estime volúmenes agregados de incidentes.

En tercer lugar, se requiere segmentación territorial temporal. Para políticas de patrullaje focalizado, prevención situacional y asignación de campañas comunitarias, es clave identificar conglomerados donde se mezclan ubicación y tiempo (coordenadas + hora + día de semana). Esto se puede realizar con un modelo de clustering, cuyo valor está en detectar agrupaciones recurrentes.

4 Dataset, volumen y justificación del enfoque Big Data

El dataset contiene 8.422.096 registros y 22 columnas en formato CSV. Por tamaño y estructura, el uso de herramientas tradicionales de análisis (por ejemplo, procesamiento en memoria con pandas en un equipo estándar) implica tiempos elevados, riesgos de desborde de memoria y baja escalabilidad. Por esto se justifica el uso de Apache Spark mediante PySpark, que permite procesamiento distribuido y optimizaciones internas (planificación de ejecución, lectura paralela, reducción de shuffles, entre otros).

Se configuró Spark con `spark.sql.shuffle.partitions = 200`. Esto porque en operaciones como `groupBy`, `count` o en entrenamiento de modelos sobre datos grandes, el número de particiones afecta tanto el paralelismo como el overhead. Un valor moderado busca equilibrio entre tiempos y costo computacional en Colab.

Además, se deshabilitó `spark.sql.ansi.enabled` para evitar que conversiones de tipo estrictas detengan la ejecución ante casos puntuales de formato. En un dataset real de larga duración, es normal que aparezcan registros con formatos inconsistentes, una canalización robusta debe tolerarlos y registrar el impacto de la limpieza.

5 Preparación de datos y construcción de la vista minable

5.1 Estandarización de columnas

El dataset original incluía nombres con espacios (por ejemplo, Case Number, Primary Type, Location Description). Se renombraron a formato compatible con pipelines (Case_Number, Primary_Type, Location_Description). Esta normalización es necesaria porque muchas operaciones de programación, sobre todo en pipelines de ML, se vuelven más seguras y mantenibles con nombres sin espacios. En entornos productivos, este tipo de estandarización evita errores y mejora la trazabilidad.

5.2 Conversión robusta de fecha y creación de variables temporales

La columna Date estaba en string con formato tipo 07/29/2022 03:39:00 AM. Se transformó a timestamp usando `unix_timestamp + from_unixtime`, generando DateTS. Esto se hace porque en Spark las conversiones directas pueden fallar con ciertas configuraciones o registros “malformados”, en cambio, `unix_timestamp` retorna NULL cuando no logra analizar, permitiendo filtrar sin detener el proceso. El propio Colab evidencia que la conversión funcionó, mostrando ejemplos donde Date se traduce correctamente a DateTS.

```
+-----+-----+
|Date           |DateTS          |
+-----+-----+
|07/29/2022 03:39:00 AM|2022-07-29 03:39:00|
|01/03/2023 04:44:00 PM|2023-01-03 16:44:00|
|08/10/2020 09:45:00 AM|2020-08-10 09:45:00|
|08/26/2017 10:00:00 AM|2017-08-26 10:00:00|
|09/06/2023 05:00:00 PM|2023-09-06 17:00:00|
+-----+-----+
only showing top 5 rows
```

A partir de DateTS se generaron variables derivadas: year, month, dow (día de semana) y hour. Esto se requiere primero porque los incidentes criminales presentan patrones temporales como diferencias por horarios, fines de semana, meses y períodos. Segundo, estos campos son una forma de transformar tiempo continuo en atributos útiles para modelos supervisados y clustering sin requerir modelos temporales complejos.

5.3 Selección de variables y filtrado crítico

Se construyó una vista minable con campos relevantes para modelado: Primary_Type, Description, Location_Description, District, Arrest, además de variables temporales y coordenadas (Latitude, Longitude) para clustering. Luego se aplicaron filtros eliminando registros sin Primary_Type, sin Arrest o sin District ya que estas columnas son insumos centrales de los modelos y su ausencia impide entrenamiento consistente. Además, mantener nulos en variables esenciales produce ruido y afecta la evaluación.

5.4 Deduplicación

Se eliminaron duplicados por ID. Dado que ID representa un identificador de incidente, la deduplicación evita conteos inflados y entrenamiento sesgado. En datasets operacionales, duplicidades pueden surgir por reprocesamientos, sincronizaciones o registros repetidos.

El resultado cuantitativo observado fue: desde 8.422.096 filas originales se obtuvo 8.422.049 filas tras limpieza y deduplicación. La diferencia es baja respecto del total, lo cual sugiere que el proceso no “perdió” datos de forma masiva y que los filtros aplicados fueron razonables.

6 Almacenamiento eficiente: Parquet particionado por año


Una decisión fue persistir el dataset limpio en formato Parquet, particionado por year, generando un repositorio con 8.422.049 filas.

Esto se justifica por desempeño ya que Parquet es columnar, soporta compresión y permite lecturas selectivas de columnas, lo que reduce Input/Output. Además, la partición por año habilita análisis y entrenamiento segmentado (por ejemplo, entrenar con años recientes, evaluar por períodos, o ejecutar consultas solo para un año).


7 Análisis exploratorio y evidencia visual

Con el objetivo de comprender el comportamiento general de los incidentes y justificar las decisiones posteriores de modelamiento, se desarrolló un análisis exploratorio apoyado en visualizaciones clave que permiten identificar patrones temporales y territoriales relevantes desde una perspectiva institucional.


En primer lugar, se analizó la evolución anual del número de incidentes registrados en la ciudad de Chicago. La serie temporal evidencia una tendencia general a la disminución de los incidentes desde los primeros años del período analizado hasta años más recientes, con fluctuaciones intermedias y cambios de pendiente en ciertos tramos. Esta visualización debe interpretarse con cautela, ya que las variaciones observadas pueden responder tanto a cambios reales en los niveles de criminalidad como a modificaciones en políticas de reporte, criterios administrativos o capacidades operativas de las instituciones. No obstante, desde un punto de vista de negocio público, este gráfico cumple un rol fundamental como marco de situación histórica, permitiendo contextualizar decisiones estratégicas, detectar posibles rupturas temporales y justificar la incorporación explícita de variables temporales en los modelos de análisis y predicción.



Complementariamente, se examinó la distribución de incidentes a lo largo de las horas del día. La visualización muestra un patrón claramente no uniforme, con mínimos durante la madrugada y un aumento progresivo a partir de las primeras horas del día, alcanzando valores elevados durante la tarde y la noche. Este comportamiento confirma que la variable temporal “hora del día” aporta información relevante y no constituye ruido estadístico. Desde la perspectiva de una institución gubernamental, este resultado es especialmente útil para la planificación operativa, ya que permite identificar ventanas horarias de mayor concentración de incidentes y respalda la inclusión de la hora como variable explicativa tanto en modelos predictivos como en análisis de segmentación espacio-temporal.



Finalmente, se analizó la distribución de incidentes por distrito, considerando los diez distritos con mayor volumen acumulado de registros. El gráfico evidencia diferencias significativas entre distritos, lo que sugiere una carga operativa desigual dentro de la ciudad. Esta heterogeneidad territorial justifica el uso del distrito como variable clave en los modelos de regresión y clustering, y refuerza su relevancia para escenarios de asignación de recursos, evaluación de presión operativa y diseño de políticas públicas focalizadas. En un contexto gubernamental, este tipo de visualización no busca establecer conclusiones causales directas, sino apoyar procesos de priorización y planificación basados en evidencia cuantitativa.



8 Modelos aplicados, configuración, evaluación e interpretación

8.1 Modelo 1: Clasificación de arresto (Logistic Regression)}

Objetivo del modelo

Estimar la probabilidad de arresto asociado a un incidente, en función de características categóricas (tipo de delito, descripción, tipo de ubicación, distrito) y temporales (hora, día de semana, mes). Con esto se puede identificar contextos con distinta tasa de arresto y

orientar medidas, por ejemplo, reforzar patrullaje en ciertos horarios y zonas o ajustar despliegue preventivo).

Justificación del algoritmo

Se seleccionó Regresión Logística por ser un clasificador fuerte como línea base en datos tabulares, escalable en Spark y relativamente interpretable. En instituciones públicas, la interpretabilidad es valiosa porque facilita explicar resultados a autoridades y auditores, además de permitir análisis de sensibilidad.

Diseño y configuración.

Se transformaron variables categóricas mediante StringIndexer y OneHotEncoder, y luego se unieron con variables numéricas usando VectorAssembler. Esto se justifica porque modelos lineales requieren entradas numéricas, la codificación one-hot evita imponer un orden artificial entre categorías. El dataset se dividió en entrenamiento/prueba (80/20) con semilla fija, lo que apoya reproducibilidad.

El modelo se entrenó con $\text{maxIter} = 30$ y $\text{regParam} = 0.1$. Se usa regularización para reducir sobreajuste, especialmente cuando se usan muchas categorías (por ejemplo, múltiples descripciones y ubicaciones).

Resultados y métricas.

El Colab arrojó:

```
AUC: 0.8969179297820058  
F1 : 0.8766624568240606
```

Estos valores son altos para un problema con múltiples categorías y variabilidad temporal. Un AUC cercano a 0.90 indica que el modelo discrimina adecuadamente entre arresto y no arresto, es decir, asigna mayores puntajes a casos que efectivamente presentan arresto con buena consistencia global. El F1 alto significa que el equilibrio entre precisión y cobertura es sólido, lo cual es importante si la clase “arresto” no es perfectamente balanceada con “no arresto”.

Interpretación aplicada al negocio.

Para una unidad pública, un modelo con este desempeño puede apoyar análisis por segmento: si en ciertos distritos, horarios o ubicaciones el modelo tiende a predecir menor

probabilidad de arresto, se puede plantear revisión de recursos, coordinación con fiscalía, o mejoras de procedimientos. No se interpreta como herramienta para “decidir arrestos”, sino como insumo estratégico para mejorar eficacia operativa y focalizar esfuerzos preventivos.

8.2 Modelo 2: Regresión de volumen de delitos por distrito/mes (GBTRRegressor)

Objetivo del modelo

Estimar la cantidad de incidentes (`crime_count`) por District, year y month. Este objetivo se alinea a planificación ya que se busca anticipar demanda agregada, no caso a caso. Para las policías, el problema habitual no es solo “qué pasará con un incidente”, sino “cuánta carga habrá en la próxima ventana temporal por zona”.

Justificación del algoritmo

Se utilizó Gradient Boosted Trees (GBT) porque es capaz de capturar relaciones no lineales y efectos de interacción entre variables temporales y distrito. En datos de conteo, un modelo lineal puede resultar insuficiente mientras que un ensamble de árboles suele ajustarse mejor a cambios de tendencia y variaciones estacionales.

Diseño y configuración

Primero se agregaron los datos con `groupBy(District, year, month).count()`, creando la variable objetivo `crime_count`. Luego se codificó District (index + one-hot) y se ensamblaron features con year y month. Se entrenó con `maxIter = 50` y `maxDepth = 6`. La profundidad controla complejidad ya que si es demasiado alta puede sobreajustar.

Resultados y métricas.

El Colab reportó:

```
RMSE: 97.83360753017251
MAE : 72.43061024420732
```

En términos operativos, esto significa que el modelo se equivoca, en promedio absoluto, en alrededor de 72 incidentes por distrito / mes, y que penalizando más los errores grandes (RMSE), el error es cercano a 98 incidentes. La interpretación depende de la escala de incidentes por distrito / mes, en distritos con cientos o miles de incidentes mensuales, este error puede ser aceptable como herramienta de planificación de recursos, sobre todo si

se utiliza para comparar “tendencias relativas” entre distritos y meses en lugar de tomarlo como número exacto.

Interpretación aplicada al negocio

Este modelo permite a una institución estimar carga mensual por distrito y apoyar decisiones como reasignación de turnos, refuerzo de campañas preventivas en meses críticos, o justificación presupuestaria. También puede integrarse en reportes ejecutivos de seguridad para priorizar inversión territorial.

8.3 Modelo 3: Clustering espacio-temporal (K-Means)

Objetivo del modelo

Identificar conglomerados (clusters) de incidentes considerando geolocalización (Latitude, Longitude) y componentes temporales (hour, dow). El propósito no es predecir, sino descubrir estructuras latentes como zonas y horarios con patrones similares. En seguridad pública, esto se utiliza para focalización de patrullajes y prevención.

Justificación del algoritmo

K-Means es un algoritmo estándar, eficiente y escalable en Spark. Es especialmente práctico cuando se requiere segmentación rápida sobre millones de registros. Se estableció $k = 8$ como número de clusters, buscando suficiente granularidad para diferenciar patrones sin caer en sobresegmentación difícil de operar.

Diseño y configuración

Se filtraron registros sin coordenadas y se convirtieron a tipo numérico (DoubleType). Luego se unieron features con VectorAssembler. Se entrenó con semilla fija para reproducibilidad.

Resultados y evaluación

El Colab reportó:

```
Silhouette: 0.5633509678133254
```

Un coeficiente de silueta sobre 0.5 se considera en muchos contextos señal de separación razonable entre clusters. No indica perfección, pero sí estructura detectada con cohesión interna.

Además, la distribución de clusters fue:

- Cluster 1: 1.289.305
- Cluster 6: 1.116.332
- Cluster 0: 1.037.163
- Cluster 5: 1.036.334

- Cluster 3: 1.013.607
- Cluster 7: 966.751
- Cluster 2: 957.756
- Cluster 4: 910.957

prediction	count
1	1289305
6	1116332
0	1037163
5	1036334
3	1013607
7	966751
2	957756
4	910957

La distribución relativamente balanceada significa que el algoritmo no colapsó en un único cluster dominante. Para negocio, esto es útil porque los clusters demasiado desbalanceados a menudo indican mala elección de k o features.

Interpretación aplicada al negocio

Estos clusters pueden ser interpretados como “segmentos” que combinan espacio y tiempo, por ejemplo, conjuntos de incidentes concentrados en ciertas zonas urbanas con horarios característicos. En un organismo público, el paso siguiente sería mapear los clusters y asociarlos a distritos / sectores, generando planes diferenciados.

9 Evaluación integral, consistencia y reproducibilidad

El flujo implementado presenta evidencia de reproducibilidad por varias razones. Se fijaron semillas en particiones y modelos. Se persistió el dataset en Parquet para reuso estable. Además, se observan salidas concretas verificables: conteo inicial, conteo final, gráfico por año y métricas numéricas de los modelos.

También se observa consistencia metodológica: los tres enfoques (clasificación, regresión, clustering) utilizan una vista minable común y derivaciones temporales coherentes. Esto fortalece el argumento de que el trabajo no es una suma de experimentos aislados, sino una canalización razonablemente integrada.

10 Limitaciones y consideraciones de uso responsable

Aunque el desempeño es alto en clasificación, debe considerarse que el dataset refleja registros históricos y decisiones institucionales pasadas. Por tanto, el modelo puede capturar patrones de operación, sesgos de reporte o variaciones por distrito asociadas a recursos disponibles, no solamente “causas” del arresto. En un uso público, el resultado debe emplearse como soporte analítico, no como automatización de decisiones legales o policiales.

En regresión, el error reportado puede ser aceptable para planificación, pero no garantiza exactitud fina para presupuestos rígidos si no se calibra por escala de cada distrito. En clustering, la elección de $k = 8$ es una decisión técnica inicial; se recomienda evaluar sensibilidad con otros valores y, especialmente, representar los clusters en un mapa para validación territorial.

11 Conclusiones finales

El desarrollo de este proyecto ha permitido validar la aplicabilidad y eficacia de las tecnologías Big Data en el ámbito de la seguridad pública, logrando procesar, limpiar y modelar exitosamente un dataset histórico de más de 8.4 millones de registros de incidentes criminales en Chicago. A través de la implementación de un flujo de trabajo en Apache Spark, se superaron las barreras de escalabilidad y rendimiento que limitan a las herramientas tradicionales, demostrando que la arquitectura distribuida es indispensable para transformar grandes volúmenes de datos brutos en conocimiento accionable.

Desde una perspectiva técnica y de arquitectura de datos, la construcción de una vista minable robusta y el almacenamiento en formato columnar Parquet particionado por año resultaron decisiones críticas para la eficiencia del sistema. La estandarización de variables y el manejo de fechas mediante `unix_timestamp` aseguraron la integridad de la información, permitiendo entrenar modelos sobre una base de datos limpia y consistente, libre de duplicados y errores de formato que pudieran sesgar los resultados.

En cuanto a la analítica predictiva y descriptiva, los tres enfoques de Machine Learning implementados respondieron satisfactoriamente a los requerimientos del negocio:

1. **Eficiencia Operativa (Clasificación):** El modelo de Regresión Logística demostró un alto desempeño con un AUC cercano a 0.90 y un F1-Score de 0.87. Esto valida su utilidad como herramienta estratégica para estimar la probabilidad de arresto, permitiendo a la institución identificar contextos de baja efectividad y optimizar protocolos de intervención.
2. **Planificación de Recursos (Regresión):** El modelo GBTRRegressor, con un error absoluto medio (MAE) de 72 incidentes, ofrece una aproximación válida para la planificación de la demanda policial por distrito y mes. Aunque no busca una exactitud contable perfecta, su capacidad para capturar tendencias no lineales lo convierte en un insumo clave para la asignación presupuestaria y de personal.
3. **Segmentación Territorial (Clustering):** La aplicación de K-Means logró identificar conglomerados espacio - temporales con un coeficiente de silueta superior a 0.56, revelando estructuras latentes en la ocurrencia de delitos que facilitan la focalización de patrullajes y campañas preventivas.

Finalmente, es imperativo destacar que, si bien los modelos presentan métricas sólidas, su implementación en un entorno gubernamental debe realizarse con un enfoque ético y de apoyo a la decisión, no de automatización total. Los resultados reflejan patrones históricos que pueden contener sesgos sistémicos. Por lo tanto, el valor real de esta solución no reside solo en los algoritmos, sino en su capacidad para proporcionar evidencia cuantitativa que complemente el criterio experto en la formulación de políticas públicas de seguridad más eficientes y objetivas.

12 Anexos

Link Google Colab:

https://colab.research.google.com/drive/1Dvcovx6n_Dp9EMHWmtUzvDd_YYSnhiU?usp=sharing

Link Dataset: <https://www.kaggle.com/datasets/har5hdeep5harma/chicago-crime-incidents-2001-to-present>